

Analisi di Serie Storiche su Dati di Ipertensione

Fase 1: Selezione e documentazione del dataset

1. Descrizione del dataset

Per lo svolgimento del progetto è stato selezionato il dataset "**Synthetic Health Data (Anomaly): 100 Patients, 10-Min**", pubblicato sulla piattaforma Kaggle dall'utente **shrishagrawal** e disponibile al seguente indirizzo: <https://www.kaggle.com/datasets/shrishagrawal/synthetic-health-dataanomaly-100patients10-min>

Il dataset è distribuito come un archivio contenente diversi file. Per il presente progetto è stato selezionato il file **realistic_synthetic_health_dataset.csv**, in quanto rappresenta il dataset principale e contiene le misurazioni fisiologiche necessarie per lo sviluppo dell'analisi delle serie temporali.

Il file contiene dati sintetici di monitoraggio sanitario continuo, progettati per simulare il comportamento di pazienti monitorati mediante dispositivi wearable (IoT). Le misurazioni sono effettuate con una frequenza di **una rilevazione ogni 10 minuti** e coprono l'intero periodo compreso tra il **1° gennaio 2025** e il **31 dicembre 2025**.

L'analisi preliminare del dataset, effettuata mediante il notebook sviluppato nella Fase 2, ha evidenziato che il file selezionato è composto da **5.256.000 osservazioni** e **22 variabili**, riferite a **100 pazienti** identificati dalla variabile **Patient_ID**.

Ogni paziente dispone di una **serie temporale completa** costituita da **52.560 osservazioni**, corrispondenti esattamente a un anno di monitoraggio continuo con una rilevazione ogni 10 minuti (**365 giorni × 24 ore × 6 misurazioni/ora**). Tale struttura rende il dataset particolarmente adatto allo studio dell'evoluzione temporale della pressione arteriosa e all'applicazione di modelli di forecasting.

Poiché l'obiettivo del progetto è sviluppare un modello di previsione **univariato** della pressione arteriosa sistolica, nelle fasi successive dell'analisi verrà selezionato un singolo paziente. La scelta sarà effettuata seguendo un criterio deterministico e riproducibile: dal momento che tutti i pazienti presentano una serie temporale completa e con il medesimo numero di osservazioni, è stato selezionato il paziente con **Patient_ID = 1**, così da garantire la completa riproducibilità dell'analisi senza introdurre criteri arbitrari di selezione.

2. Descrizione delle variabili

Il file **realistic_synthetic_health_dataset.csv** è composto da **22 variabili**, che descrivono sia le caratteristiche anagrafiche dei pazienti sia i principali parametri fisiologici monitorati nel tempo, oltre ad alcune informazioni relative alla qualità del dato e alla presenza di anomalie.

Le variabili possono essere raggruppate nelle seguenti categorie:

- **Variabili anagrafiche**, che descrivono le caratteristiche del paziente e comprendono **Patient_ID**, **Age**, **Gender**, **Weight**, **Height** e **BMI**;
- **Segnali vitali monitorati nel tempo**, che costituiscono la componente principale della serie storica e comprendono **Timestamp**, **Heart_Rate**, **BP_Systolic**, **BP_Diastolic**, **SpO₂**, **Respiration_Rate**, **Body_Temperature** e **Blood_Glucose**;
- **Variabili comportamentali**, rappresentate da **Activity_Level** e **Sleep_Pattern**, che descrivono il livello di attività fisica e il comportamento del paziente durante il monitoraggio;
- **Variabili cliniche e di qualità del dato**, costituite da **Risk_Profile**, **Hypertension_Label**, **Anomaly_Type**, **Is_Anomaly**, **Data_Quality_Flag** e **Missing_Mechanism**, che forniscono informazioni sul profilo di rischio cardiovascolare, sulla presenza di ipertensione e sulle eventuali anomalie o valori mancanti presenti nel dataset.

Tra tutte le variabili, **Timestamp** rappresenta la dimensione temporale dell'analisi, mentre **BP_Systolic** (pressione arteriosa sistolica) costituisce la **variabile target** del progetto, in quanto sarà utilizzata per sviluppare e confrontare i modelli di previsione delle serie storiche. La variabile **BP_Diastolic** verrà invece considerata come parametro clinico di supporto nell'analisi esplorativa.

La presenza della variabile **Hypertension_Label**, che identifica la presenza o l'assenza di una condizione ipertensiva, rende il dataset pienamente coerente con il tema dell'ipertensione arteriosa richiesto dalla consegna. Inoltre, le variabili **Is_Anomaly**, **Anomaly_Type**, **Data_Quality_Flag** e **Missing_Mechanism** consentono di individuare osservazioni anomale, errori di acquisizione e valori mancanti, risultando particolarmente utili durante le fasi di pre-processing e pulizia dei dati previste nella Fase 2 del progetto.

3. Motivazione della scelta

La scelta del dataset è stata preceduta da un confronto con altri dataset disponibili su Kaggle, valutati in funzione dei requisiti richiesti dalla consegna.

In particolare, un primo dataset è stato escluso perché presentava una struttura di tipo **panel**, caratterizzata da poche osservazioni per ciascun paziente e dall'assenza di una serie temporale continua. Tale struttura non risultava quindi idonea all'applicazione di modelli di forecasting basati su serie storiche.

Successivamente è stato analizzato un secondo dataset sintetico di monitoraggio cardiovascolare, costituito da rilevazioni orarie distribuite su un periodo di 30 giorni. Sebbene questo dataset soddisfacesse il requisito della presenza di una variabile temporale, una prima analisi esplorativa ha evidenziato una scarsa dipendenza temporale delle osservazioni, rendendolo poco adatto allo sviluppo di modelli previsionali basati sulla dinamica della serie.

Il dataset **realistic_synthetic_health_dataset.csv** è stato quindi selezionato perché presenta caratteristiche maggiormente coerenti con gli obiettivi del progetto. In particolare:

- dispone di una variabile temporale con rilevazioni effettuate ogni **10 minuti** per un intero anno;
- contiene serie temporali sufficientemente lunghe e continue, indispensabili per l'applicazione dei modelli di forecasting;
- include misure fisiologiche direttamente correlate all'ipertensione arteriosa, come la pressione sistolica e diastolica;
- mette a disposizione variabili cliniche e comportamentali che consentono una più completa interpretazione dei dati;
- include informazioni sulla qualità del dato, sulla presenza di anomalie e sui meccanismi di generazione dei valori mancanti, risultando particolarmente utile per le attività di pre-processing.

Le verifiche statistiche effettuate nella successiva Fase 2 hanno inoltre confermato la presenza di una struttura temporale significativa, con evidenze di autocorrelazione e stagionalità, rendendo il dataset adeguato all'applicazione dei modelli di analisi e previsione richiesti dalla consegna.

4. Problematiche etiche e di privacy

Il dataset è dichiarato **sintetico** dall'autore: i pazienti e le relative misurazioni sono generati artificialmente, senza alcuna corrispondenza con soggetti reali. Non sussistono pertanto problemi di identificabilità, consenso informato o applicabilità di normative sulla protezione dei dati sanitari.

Va comunque segnalato, come limite metodologico, che trattandosi di dati simulati le relazioni fisiologiche osservate (ad esempio tra attività fisica, sonno e pressione arteriosa) riflettono le assunzioni del generatore sintetico e non necessariamente la reale complessità clinica dell'ipertensione. I risultati del progetto vanno quindi interpretati come validazione della pipeline metodologica di analisi di serie storiche, più che come evidenza clinica in senso stretto.